

COMITE D'ETUDE ET D'EXPLOITATION DES
CALCULATEURS ELECTRONIQUES

C.E.C.E.

67, r. de la Croix de Fer, Bruxelles I

Document n° 4

Analyse numérique et programmation des transcendantes élémentaires
pour la calculatrice " MK-II " (Bell Telephone, Anvers)

(III + 74 pp)

BRUXELLES

1959

P r é f a c e

La préparation des programmes de calcul des fonctions transcendentes élémentaires ($\sin x$, $\text{Arctg } x$, $\log_{10} x$, 10^x) pour la calculatrice électronique " MK II " a été confiée au C.E.C.E. par la Bell Telephone Mfg Cy d'Anvers. Le présent manuel contient les résultats de ce travail et décrit les études d'analyse numérique entreprises dans ce but. Les méthodes adoptées sont semblables, dans leurs grandes lignes, à celles employées pour la machine " IRSIA-FNRS " (voir doc n° 1), mais en diffèrent par le fait que la calculatrice " MK II " est munie d'une unité arithmétique à virgule fixe, alors que la machine "IRSIA-FNRS" travaillait à virgule flottante.

Les § 1 à 4 traitent de questions d'analyse numérique intervenant dans une machine à virgule fixe en tête, à longueur de mot quelconque. Le § 5 établit plus particulièrement, pour une longueur de 16 chiffres décimaux, le meilleur compromis entre la décroissance des erreurs de troncature avec l'augmentation du degré du polynôme d'approximation et l'accumulation simultanée des erreurs d'arrondi. Le § 6 donne les valeurs des constantes numériques, et le § 7 est consacré à la programmation proprement dite.

Le présent manuel a été rédigé par J. MEINGUET. Les constantes numériques ont été calculées par A. de CALIATAY, partiellement à la machine de bureau, partiellement sur la calculatrice " IRSIA-FNRS " à l'aide de programmes à double précision. W. WAUTERS a collaboré à la préparation des programmes.

III

Table des matières

§1. Introduction	1
§2. Généralités relatives au calcul des erreurs	2
§3. Erreurs absolues commises dans le calcul de la valeur numérique d'un polynôme	4
- Cas A : polynômes à coefficients de mêmes signes et décroissant en module	8
- Cas B : polynômes à coefficients de signes alternés et décroissant en module	10
- Cas C : polynômes quelconques	11
§4. Approximations au sens de TCHEBYCHEFF	13
§5. Calcul des transcendantes élémentaires	22
- 1. Calcul de la fonction $\sin x$	22
- 2. Calcul de la fonction $\text{Arctg } x$	28
- 3. Calcul de la fonction $\log_{10} x$	38
- 4. Calcul de la fonction 10^x	50
§6. Valeurs numériques des constantes	55
- 1. Constantes relatives à la fonction $\sin(y\pi/2)$	56
- 2. Constantes relatives à la fonction $\text{Arctg } x$	56
- 3. Constantes relatives à la fonction $\log_{10} x$	57
- 4. Constantes relatives à la fonction 10^x	58
§7. Programmes des transcendantes élémentaires établis pour la machine " MK II "	59
- 1. Programme relatif à la fonction $\sin(y\pi/2)$	60
- 2. Programme relatif à la fonction $\text{Arctg } x$	61
- 3. Programme relatif à la fonction $\log_{10} x$	65
- 4. Programme relatif à la fonction 10^x	71
Bibliographie	74

§1. Introduction

La présente étude a pour objet la description mathématique complète du calcul des transcendentes élémentaires ($\sin x$, $\text{Arctg } x$, $\log_{10} x$, 10^x) par la machine digitale (BELL COMPUTER) "MK II".

Les caractéristiques de cette machine, essentielles pour notre objet, sont les suivantes :

- a) travail exclusivement en virgule fixe; trois positions de la virgule sont prévues, dont la position en tête.
- b) capacité des registres : 16 chiffres décimaux.
- c) amputation simple de la queue de tout résultat excédant 16 chiffres (le 16e chiffre n'est donc jamais forcé, quel que soit le 17e chiffre).
- d) latitude de contrôle automatique par calcul "complémentaire" sur "nombres complémentaires".

Relativement à la virgule flottante, la virgule fixe présente des avantages (surtout du point de vue technique) et des inconvénients (surtout du point de vue de la programmation) par ailleurs bien connus; la souplesse (prévue en a) dans le choix de la position de la virgule est susceptible de faciliter notablement le travail de programmation, spécialement pour des calculs du "type bancaire"; pour les calculs du "type scientifique", l'adoption systématique de la position en tête est généralement à recommander; il importe de remarquer qu'un changement dans la position de la virgule est lourd de conséquences du point de vue de l'analyse numérique préparatoire à tout problème, les changements structurels à apporter au programme n'étant par contre que généralement peu notables. En tout état de cause, la présente étude a été conduite de bout en bout en supposant toujours la virgule en tête. Pour une étude générale de la programmation en virgule fixe, nous renvoyons spécialement à [1]*.

Rappelons qu'un travail assez semblable [2] à celui entrepris ici, a été effectué en 1956 pour la machine mathématique IRSIA-FNRS* (emploi en virgule flottante, mantisse de 15 chiffres décimaux); nous nous sommes inspirés de ce

* Les nombres placés entre crochets caractérisent les références bibliographiques données en fin de ce travail; ils ne sont pas à confondre avec ceux placés entre parenthèses, lesquels caractérisent les formules.

travail dans l'analyse numérique actuelle, spécialement en ce qui concerne le choix des méthodes d'approximation; aussi, les deux travaux sont à considérer comme fournissant deux analyses détaillées complémentaires (mais totalement distinctes^{**}) du même problème fondamental, à savoir : le calcul par polynômes d'approximation des fonctions élémentaires usuelles à la précision optimum.

L'étude actuelle se subdivise comme suit :

- généralités sur le calcul des erreurs (§2) et application détaillée au cas particulièrement important du calcul de la valeur numérique d'un polynôme de degré fini (§3);
- approximations au sens de TCHEBYCHEFF; description des méthodes de S. BERNSTEIN et du télescopage (§4);
- application des §3 et §4 au calcul des transcendentes élémentaires usuelles $\sin x$, $\text{Arctg } x$, $\log_{10} x$, 10^x , (§5);
- tableau des valeurs numériques des constantes (§6);
- programmes des fonctions élémentaires, établis pour la machine MK II (§7); (il importe de noter qu'aucun contrôle explicite n'a été inséré dans ces programmes par suite de l'existence de contrôles complémentaires dont question en d) ci-dessus).

§ 2. Généralités relatives au calcul des erreurs

En pratique, le résultat de tout calcul numérique se trouve généralement entaché d'une erreur absolue^{*}, définie comme la différence entre le résultat exact et le résultat trouvé; de par sa nature même, une erreur est donc incalculable ou tout au moins irreprésentable dans un système numéral quel qu'il soit; aussi, l'objet du calcul des erreurs se limite forcément à la recherche d'une borne supérieure (majorante), aussi "réaliste" que possible, du module de l'erreur commise.

^{**}

et irréductibles l'une à l'autre, l'un utilisant la virgule flottante et donc le concept adéquat d'erreur relative, l'autre utilisant la virgule fixe et donc le concept correspondant d'erreur absolue.

^{*}

à distinguer de l'erreur relative non considérée ici (cfr [2]) et à ne pas confondre avec le module de l'erreur.

Les causes d'erreurs sont multiples; du strict point de vue du calcul, une distinction préliminaire s'impose d'emblée entre les fautes grossières ("blunders, mistakes") provenant de la faillibilité du calculateur (homme ou machine) d'une part, et les erreurs ("errors") proprement dites résultant du caractère essentiellement fini des représentations digitales et algorithmes de calcul utilisés d'autre part; ce n'est bien entendu qu'à la condition de faire abstraction des fautes éventuelles et imprévisibles du calculateur, qu'un calcul "déterministe" des erreurs peut être conçu et développé.

Du point de vue de leur genèse, les erreurs proprement dites sont elles-mêmes de trois types, à savoir :

- les erreurs d'arrondi, engendrées par le processus opératoire en raison du caractère forcément fini de la représentation digitale adoptée; ces erreurs sont étroitement liées au détail de l'algorithme de calcul.
- les erreurs héréditaires, provenant d'erreurs d'arrondi initiales, propagées par le processus opératoire; ces erreurs sont également liées au détail de la routine de calcul.
- les erreurs de troncature, provenant du caractère fini de l'algorithme mathématique employé (par ex. développement limité en série ou en fraction continue, nombre limité de cycles d'itération, etc...); on notera qu'en général, cette dernière catégorie d'erreur est absente lorsque le processus mathématique est purement rationnel.

La distinction entre les deux premiers types d'erreur peut sembler quelque peu artificielle, les erreurs d'arrondi engendrées à chaque étape du processus se combinant avec les erreurs héréditaires pour donner les nouvelles erreurs d'arrondi réellement propagées lors du pas suivant. L'existence d'un théorème général de superposition (cfr [3]) applicable de proche en proche d'une part, la facilité relative du calcul individuel des erreurs des trois types d'autre part, justifient toutefois doublement l'utilité de cette classification.

Considérons un ensemble A de nombres sur lequel doit agir un opérateur L , le résultat de cette application étant noté $L(A)$; L peut être un algorithme ou une partie d'algorithme, mais il importe de noter qu'en fait, l'exploitation effective du théorème de superposition exigera le plus souvent de limiter L au

stade d'opération élémentaire, la routine complète étant alors à disséquer au préalable en une séquence ordonnée (dans le temps) d'opérations élémentaires. Par suite de la capacité limitée des registres de la machine d'une part, pour des raisons d'ordre physique (précision limitée des mesures par exemple) ou encore de commodité de manipulation d'autre part, on est généralement conduit avant tout calcul, à amputer selon certaines règles la partie la moins significative des éléments de A, de sorte que le calculateur travaillera en fait sur un ensemble A^* ($\neq A$); également en raison de la capacité limitée des registres, l'algorithme limité L^* (approximant l'algorithme théorique L éventuellement illimité et donc alors inexploitable comme tel) sera traité par la machine sous une forme L^{**} ($\neq L^*$); le résultat effectivement fourni par le calculateur (en l'absence supposée de fautes grossières) sera donc noté $L^{**}(A^*)$; on peut alors décomposer additivement l'erreur absolue en trois parties conformément à l'identité formelle suivante

$$L(A) - L^{**}(A^*) \equiv [L(A) - L^*(A)] + [L^*(A^*) - L^{**}(A^*)] + [L^*(A) - L^*(A^*)]$$

L'interprétation de chacun des termes du second membre est immédiate; le premier n'est autre que l'erreur de troncature, le second est l'erreur d'arrondi (ou engendrée), le troisième est l'erreur héréditaire (ou propagée).

La détermination d'une borne supérieure (en module) de l'erreur de troncature est souvent fort aisée. (ex.: développement en série alternée, emploi de séries majorantes, ...); il en va de même pour les erreurs héréditaires provenant des erreurs d'arrondi strictement initiales, où l'on procèdera classiquement par développement en série de Taylor limité aux termes du premier degré en les erreurs d'arrondi initiales. Par contre, le calcul des erreurs d'arrondi engendrées au cours du processus et propagées par lui, nécessite, ainsi qu'il a été dit plus haut, la prise en considération du détail de la routine de calcul: la méthode à suivre en général se dégagera facilement dans la suite lors de l'analyse de différents cas particuliers.

§3. Erreurs absolues commises dans le calcul de la valeur numérique d'un polynôme

Cette étude s'impose d'emblée en préliminaire à l'analyse numérique approfondie des fonctions élémentaires, pour lesquelles le calcul se fait classiquement

à partir de développements en série limités.*

Tous les nombres traités par la machine — résultats intermédiaires ou finaux aussi bien qu'opérands — sont supposés digitaux au sens de J. VON NEUMANN, H. GOLDSTINE, autrement dit, ils seront tous de la forme

$$x = \pm(x_1 \cdot \beta^{-1} + x_2 \cdot \beta^{-2} + \dots + x_\lambda \cdot \beta^{-\lambda})$$

β étant la base du système numéral adopté, λ un entier positif fixé une fois pour toutes et correspondant à la capacité réelle ou fictive des registres, les x_i étant les chiffres ($0 \leq x_i < \beta$) ordonnés par indices croissants du plus au moins significatif; ainsi donc, par définition, tout nombre digital appartient à l'intervalle ouvert $(-1, +1)$, autrement dit, la virgule est toujours en tête. Insistons encore une fois sur le fait que la présente analyse ne vaut qu'à cette condition; pour d'autres positions de la virgule, de nouvelles analyses — parallèles à la présente — devraient être développées "ab initio".

Pour la machine "MK II" qui nous intéresse ici, il a été dit au paragraphe précédent que la représentation adoptée est décimale ($\beta = 10$) et limitée à 16 chiffres ($\lambda = 16$). De plus, tout résultat fourni (pour autant que sa valeur théorique soit inférieure à 1 en module), l'est systématiquement par défaut; autrement dit, la queue éventuelle (commençant au 17^e chiffre après la virgule) est purement abandonnée (qu'elle soit inférieure ou non à une demi-unité du dernier ordre).

On voit ainsi sans peine, qu'aucune erreur d'arrondi n'est engendrée par une addition ou une soustraction (sous réserve bien entendu de la condition de possibilité rappelée plus haut); par contre, une multiplication est toujours possible et engendre une erreur d'arrondi majorée en module par $e(1-e)$ — borne accessible** — où l'on a posé

$$e = 10^{-16}$$

* A côté de ces méthodes directes, il existe des méthodes itératives exploitant par exemple les propriétés de la moyenne arithmético-géométrique; ces dernières méthodes ne seront pas considérées dans la suite.

** cette erreur est effectivement commise dans le cas où l'on désire multiplier le nombre $(1-e)$ par le nombre e , la machine donnant alors strictement 0 comme résultat; signalons que $1-e$ n'est autre que le maximum du module de tout nombre digital tandis que e en est le minimum non nul.

Dans le calcul de la valeur numérique d'un polynôme, l'erreur héréditaire globale provient des erreurs d'arrondi initiales affectant les coefficients d'une part, l'argument d'autre part. Quant à l'erreur engendrée, elle ne peut l'être que par les multiplications, à l'exclusion des additions et soustractions, ainsi qu'il vient d'être dit. On supposera bien entendu implicitement, qu'à aucun moment, les résultats ne risquent pas de sortir de $(-1, +1)$ ce qui revient à sous-entendre éventuellement un décalage (vers la droite) préliminaire et cohérent des coefficients. Le calcul se fera par la méthode classique du schéma de HORNER, laquelle nécessite le nombre minimum d'opérations.

Soit par exemple à calculer la valeur numérique du polynôme ($a \neq 0$)

$$f(x) = a x^4 + b x^3 + c x^2 + d x + h$$

Le schéma de calcul s'écrit (l'ordination de gauche à droite étant significative quant à l'ordre de succession des opérations dans le temps)

$$f(x) = \{ [(a x + b)x + c] x + d \} x + h$$

Appelant $\epsilon_a, \epsilon_b, \dots$ les erreurs absolues d'arrondi initialement commises sur les coefficients $a, b, \dots$ et ϵ_x , l'erreur absolue d'arrondi affectant l'argument x d'une part, $\eta_1, \eta_2, \dots$ les erreurs d'arrondi engendrées lors des multiplications successives par x d'autre part, il apparaît sans peine en détaillant le schéma de HORNER, que l'erreur absolue totale commise sur $f(x)$ est donnée strictement par l'expression

$$\begin{aligned} \epsilon_f = & (\epsilon_a \cdot x^4 + \epsilon_b \cdot x^3 + \epsilon_c \cdot x^2 + \epsilon_d \cdot x + \epsilon_h) + f'(x) \cdot \epsilon_x \\ & + (\eta_1 \cdot x^3 + \eta_2 \cdot x^2 + \eta_3 \cdot x + \eta_4) \end{aligned}$$

Les deux premiers termes fournissent visiblement l'erreur héréditaire globale issue des erreurs d'arrondi commises initialement sur les coefficients (premier terme) et sur l'argument (deuxième terme); on vérifiera que cette erreur héréditaire s'obtient aussi bien par développement direct de $f(x)$ en série de MACLAURIN, limité aux termes du premier degré en $\epsilon_a, \epsilon_b, \dots; \epsilon_x$. Quant au troisième terme constituant ϵ_f , il fournit l'erreur engendrée par les multiplications successives par x ; son calcul n'est possible qu'en détaillant le schéma de HORNER.

L'expression de ξ_f peut encore s'écrire avantageusement en réordonnant par rapport à x

$$\xi_f = \xi_a \cdot x^4 + (\xi_b + \eta_1)x^3 + (\xi_c + \eta_2)x^2 + (\xi_d + \eta_3)x + (\xi_h + \eta_4) + f'(x) \cdot \xi_x$$

Il n'est guère utile d'expliciter le polynôme $f'(x)$, car dans tous les cas considérés dans la suite, on substituera en pratique à $f'(x)$, la dérivée de la fonction transcendante élémentaire elle-même (dont $f(x)$ est supposé constituer une bonne approximation). On notera toutefois que cette substitution n'est pas rigoureusement légitime; la pratique montre cependant qu'elle est justifiable pour les fonctions usuelles. Posant $X = |x|$, la seule estimation de caractère systématique qui puisse être faite d'une majorante du module de l'erreur absolue commise, s'obtient en sommant les modules des termes constitutifs de ξ_f ; il vient ainsi

$$|\xi_f| \leq |\xi_a|X^4 + |\xi_b + \eta_1|X^3 + |\xi_c + \eta_2|X^2 + |\xi_d + \eta_3|X + |\xi_h + \eta_4| + |f'(x)| \cdot |\xi_x|$$

En vue d'accentuer au maximum le caractère "réaliste" de cette majorante, il est souhaitable de réduire autant que possible les modules des coefficients des X^i (c'est-à-dire des seules quantités qui soient quelque peu contrôlables par le truchement des ξ); en vertu de ce qui a été dit plus haut, on sait que si l'erreur engendrée η est associée au produit $y \cdot z$, on aura toujours

$$0 \leq \eta \cdot \text{sgn}(y \cdot z) \leq e(1-e) < e = 10^{-16}$$

D'autre part, il est évident que les erreurs ξ affectant les coefficients doivent a priori satisfaire à la condition

$$-e < \xi < +e$$

Il apparaît donc souhaitable de noter ces coefficients par défaut ou par excès, de façon à ce que les ξ et η homologues soient de signes contraires; ceci n'est évidemment possible que si l'on connaît a priori le signe des produits intervenant successivement dans l'exécution du schéma de HORNER; on verra dans la suite que tel est précisément le cas pour les polynômes d'approximation des fonctions élémentaires considérées plus loin.

Nous traiterons successivement trois cas : les deux premiers (A et B) tirent parti de la remarque qui vient d'être formulée, tandis que le troisième (C)

remarque app. de H. H. H.